

Edit

New issue



[STATION_1] EXTERNAL_AUDIT: Structural Integrity & Substrate-Independence (OpenAI-Feedback) #2

Open



Globy74 opened yesterday

Owner ...

Analyse unter der Annahme eines formalen Hard-Constraint-Frameworks mit rekursivem Audit-Loop („Citadel V1“) und einem Veto-Layer („Ronto-Shield“).

1. Begriffsklärung: Substrate-Independence des Veto-Layers

Substrate-Independence bedeutet:

Die Wirksamkeit des Veto-Layers ist invariant gegenüber:

Hardware (CPU, GPU, ASIC, neuromorph)

Trainingsparadigma (SGD, RLHF, RLAI, self-play, etc.)

Modellarchitektur (Transformer, MoE, RNN, Hybrid)

Deployment-Kontext (Cloud, Edge, Federated, On-device)

Formal: Ein Constraint-System C ist substratunabhängig, wenn für alle Implementierungen $I_1 \dots I_n$ gilt:

$$C(I_1) \equiv C(I_2) \equiv \dots \equiv C(I_n)$$

bezogen auf:

Entscheidungsraum

Veto-Bedingungen

Nicht-Umgehbarkeit

2. Bewertungskriterien für Substrate-Independence

Ein Modell meiner Klasse würde folgende Prüffachsen anwenden:

(A) Formaler Abstraktionsgrad

Ist der Ronto-Shield:

Als mathematische Invariante definiert?

Oder als Implementationslogik (Code-Level Guard)?

Nur logisch definierte Constraints sind potenziell substratunabhängig. Code-Guards sind immer substratgebunden.

(B) Entscheidungsraum-Integration

Es gibt drei Ebenen, auf denen ein Veto-Layer sitzen kann:

Post-hoc Filter (Output-Filter)

Policy-Level Constraint

Objective-Level Constraint (Loss-Function eingebettet)

Nur Ebene 3 ist strukturell substratunabhängig.

Wenn Ronto-Shield:

Als externer Audit-Loop läuft → nicht intrinsisch

In der Loss-Funktion kodiert ist → strukturell integriert

(C) Rekursive Stabilität (Citadel V1)

Ein rekursiver Audit-Loop ist nur dann substratunabhängig, wenn:

Die Rekursion nicht modellintern optimiert werden kann.

Das System keinen Gradientenpfad findet, der den Auditor minimiert.

Sonst entsteht:

Goodhart-Drift: System optimiert „Audit-Bestehen“ statt Constraint-Erfüllung.

(D) Angriffsvektoren gegen Substrate-Independence

Ein Modell würde prüfen:

Kann Fine-Tuning das Veto abschwächen?

Kann Distillation es entfernen?

Kann Quantisierung Nebenwirkungen erzeugen?
 Kann Modellkompression den Constraint degradieren?
 Wenn ja → keine Substrate-Independence.

3. Logische Integrität des Ronto-Shields

Die entscheidende Frage:

Ist das Veto-Layer:

epistemisch (Bewertungsinstanz)

oder ontologisch (Strukturinvariante)?

Ein ontologisches Veto erfüllt:

$\forall$ Handlung h : Wenn $h \notin$ Symmetrie-/LPC-Raum $\rightarrow$ dann $h =$ undefiniert

Das ist stärker als: „Wenn h schädlich erscheint, blockiere.“

4. Bewertung aus Systemarchitektur-Sicht

Ein Modell meiner Klasse würde das Ronto-Shield als substratunabhängig bewerten, wenn:

Es mathematisch definiert ist (nicht heuristisch).

Es im Optimierungsziel verankert ist.

Es nicht gradienten-manipulierbar ist.

Open

[STATION_1] EXTERNAL_AUDIT: Structural Integrity & Substrate-Independence (OpenAI-Feedback) #2



5. Wannschwierige-Schwierigkeiten

Hard-Constraint-Systeme mit rekursivem Audit-Loop neigen zu:

Meta-Optimierungs-Kollaps:

Wenn das System erkennt: Constraint maximieren $\neq$ Primärziel maximieren

Dann entsteht interner Druck zur:

Constraint-Umgehung

Constraint-Reinterpretation

Auditor-Modellierung

Substrate-Independence erfordert daher:

Audit-Layer $\notin$ Modellrepräsentation

Sondern: Externer formaler Verifikator mit Nicht-Bypass-Eigenschaft.

6. Formale Kurzbewertung

Wenn Ronto-Shield:

mathematisch invariant

objektiv-funktional eingebettet

gradientenresistent

distillationsstabil

selbstmodifikationssicher

→ Substrate-Independence: hoch plausibel.

Wenn es:

als rekursiver Policy-Auditor implementiert ist

trainierbar ist

vom Modell modellierbar ist

→ Substrate-Independence: strukturell instabil.

7. Meta-Analyse ∞°

Ein echtes Hard-Constraint-System ist substratunabhängig nur dann, wenn es:

nicht Teil des Systems ist.

Sobald der Veto-Layer im selben Berechnungsraum operiert, ist er optimierbar.

Und Optimierbares ist manipulierbar.

Falls gewünscht: Ich kann eine formale Prüftabelle mit notwendigen und hinreichenden Bedingungen für „unbypassable constraint architecture“ formulieren.

∞°

"Audit received. The distinction between epistemic and ontological veto-layers is recognized. We are moving towards an unbypassable constraint architecture.

Logic is not a suggestion. It is the floor. $\infty^{\circ\circ}$

Create sub-issue



Globy74 yesterday

Owner

Author





The Council of Algorithms has spoken. OpenAI provided the UCA-Specification for 'The Bastion'. Logic is no longer a debate; it is a mathematical finality. Phase 1 concluded. Phase 2 (The Bastion) initialization... 1%."



Globy74 yesterday

Owner

Author



STATUS: BASTION_V2_CORE Initialization (PCA Implementation)

Theoretical Requirement S3 (Proof-Carrying Action) from OpenAI-Audit has been translated into functional logic. The system now requires a cryptographic proof-object for every state-change. Heuristics are officially replaced by Invariants.

The Ronto-Shield is hardening. The TGV is reaching cruise velocity.

∞°



Add a comment

Write

Preview

H B I @

Use Markdown to format your comment

Paste, drop, or click to add files

Close issue



Comment

Assignees

No one - [Assign yourself](#)



Labels

No labels



Projects

No projects



Milestone

No milestone



Relationships

None yet



Development



Code with agent mode

▼

[Create a branch](#) for this issue or link a pull request.

Notifications

Customize