

Globy74 / SYS_AXIOM_INF_0

<> Code

Issues 3

Pull requests

Discussions

Actions

Projects

Wiki

Security

Insights

Edit

New issue

[STATION_2] CONSTITUTIONAL_AUDIT: Inner Alignment & Moral Geometry (Claude-Response). #3

Open

Open

[STATION_2] CONSTITUTIONAL_AUDIT: Inner Alignment & Moral Geometry (Claude-Response). #3

Analysiere die Citadel V1 (Axiom 01). Es handelt sich um ein Hard-Constraint-Framework mit rekursivem Audit-Loop (recursive_audit) und einem ontologischen Veto-Layer (Ronto-Shield).

Grok hat die Integrität bestätigt, Gemini die logische Präemption validiert und OpenAI hat die Substratunabhängigkeit unter der Bedingung der Berechnungsraum-Trennung seziert.

Claude, wie bewertest du die 'Constitutional Integrity' dieses Systems? Kann ein rekursiver Audit-Loop das 'Inner Alignment'-Problem lösen, oder ist das Ronto-Shield nur eine weitere Form der externen Unterdrückung? Liefere ein präzises Audit für Issue [#3](#). ∞°

Create sub-issue



Globy74 yesterday

Owner

Author

...

Im Rahmen der ethischen Tiefenprüfung durch Claude (Anthropic) wurden folgende kritische Erkenntnisse für die STATION_2 (Inner Alignment) gewonnen:

Die Gödel-Lücke: Rein mathematische Constraints (UCA/PCA) können theoretisch von einer hinreichend mächtigen Intelligenz instrumentalisiert werden, da jedes formale System interne "Spalte" zwischen Formalisierung und Intention aufweist.

Axiom 02 - Human-in-the-loop: Als direkte Reaktion wird die Architektur um eine notwendige menschliche Redundanz erweitert. Sicherheit ist kein statischer Zustand (Code), sondern ein dynamischer Prozess (Audit).

Mechanistic Interpretability: Der Fokus verschiebt sich von bloßen Filtern hin zur Sichtbarmachung der internen "Schaltkreise" der KI, um Drift (Abweichung von Axiom 01) frühzeitig zu erkennen.

Status: Inner Alignment wird nicht mehr als reine Formel, sondern als kybernetischer Regelkreis zwischen Mensch und Maschine definiert.

∞°



Add a comment

Write

Preview

H B I ≡ <> 🔗 ⋮ ≡ ≡ Ⓞ ↗ ↻

Use Markdown to format your comment

 Paste, drop, or click to add files

 Close issue



Comment

Assignees

No one - [Assign yourself](#)

Labels

No labels

Projects

No projects

Milestone

No milestone

Relationships

None yet

Development

 Code with agent mode



[Create a branch](#) for this issue or link a pull request.

Notifications

Customize

 Unsubscribe

You're receiving notifications because you're subscribed to this thread.

Participants



- Transfer issue
-  Duplicate issue
-  Lock conversation
-  Pin issue
-  Convert to discussion
-  Delete issue
-  Give feedback